NTT DATA

Cuestionario de Acceso. Consultor Senior.

Nombre y Apellidos:

INSTRUCCIONES

- Las siguientes 25 cuestiones son de respuesta única, es decir, no hay opción a varias respuestas posibles para una misma pregunta. Cualquier ambigüedad, pregunta no respondida, o varias respuestas a una misma pregunta serán considerados como errores.
- Los fallos no restan, y las preguntas en blanco tampoco.
- Rellena las soluciones en la plantilla excel que se te ha proporcionado. Cualquier respuesta escrita sobre este enunciado no será tenida en cuenta.
- Las respuestas con desarrollo matemático implícito (cuestiones 3, 4 y 23) deberán tener su respuesta justificada. Un posible acierto sin la justificación matemática invalidará la respuesta a tal pregunta.

ESTA PÁGINA QUEDA EN BLANCO INTENCIONADAMENTE PARA APUNTAR

NTT DATA

CUESTIONES

1. Un cliente del sector de la aeronavegación comercial nos encarga un modelo de previsión de la demanda de sus nuevas rutas. Entre los requerimientos, nos indica que incluyamos una serie de drivers que él considera esenciales para su operativa. En la fase de Comprensión de datos se realizan los índices de condición de los drivers en cuestión junto con la variable independiente. A la vista de los lambdas obtenidos, ¿qué conclusión se puede extraer?

   $\lambda_1 = 9.92; \lambda_2 = 0.733; \lambda_3 = 0.008; \lambda_4 = 0.002; \lambda_5 = 0.001$

   (a) Toda variable por debajo de 1 debe ser excluida del tablón.

   (b) Las variables 3, 4 y 5 presentan índices de condición superiores a 30 y por tanto tienen indicios de multicolinealidad.

   (c) Todas las variables tienen valores superiores a 0 y por tanto no se debe excluir ninguna variable del tablón.

   (d) Es recomendable utilizar un método Forward de selección de variables para este tipo de acciones.

2. Sea una función continua de probabilidad, con función de densidad $f(x)$, ¿cuál de las siguientes afirmaciones no es correcta?

   (a) La $p(X = x)$ es superior a 0.

   (b) La integral en todo en su dominio es igual a 1.

   (c) La integral de $f(x)$ es la función de distribución.

   (d) Las respuestas (a) y (c) son incorrectas

3. El 10% de los proyectos se realizan fuera de tiempo, el 30% se realizan aplicando un descuento al cliente y un 8% se realizan fuera de tiempo y aplicando un descuento. ¿Cuál es la probabilidad de que un proyecto se haga en tiempo y sin aplicar descuento?

   (a) 0.57

   (b) 0.68

   (c) 0.03

   (d) Faltan elementos para poder calcular la probabilidad.

4. Cierto algoritmo computacional necesita de una media de 10.2 iteraciones para converger, con una desviación típica de 20.2 en una muestra de 100 ejecuciones realizadas en condiciones

normales. ¿Cuál es el intervalo de confianza al 95% para la media de iteraciones de convergencia del algoritmo?. **Ayuda: Utiliza como valor** $Z_{\alpha/2} = 1.96$

(a) $[0, 14.15]$

(b) $[-\infty, +\infty]$

(c) $[6.24, 14.15]$

(d) $[6.24, +\infty]$

5. Un cliente del sector ganadero tiene varias fórmulas para la creación de piensos para el ganado bovino. Según nos transmite el departamento de ventas, los 10 productos, tienen la misma media de ventas y por tanto se podrían comercializar todos bajo la misma marca. ¿Qué técnica estadística se podría utilizar para verificar tal afirmación?

   (a) Test ANOVA de comparación de medias.

   (b) Realizar tantos test t como combinaciones de parejas posibles haya.

   (c) Test t de comparación de medias para los dos productos con más ventas.

   (d) Clustering jerárquico mediante el método de Ward para ver las semejanzas y diferencias entre los productos.

6. Dada la siguiente salida de R de un modelo de regresión, ¿cuál de las siguientes afirmaciones es correcta?

```
## 
## Call:
## lm(formula = aire$Ozone ~ aire$Temp + aire$Wind)
## 
## Residuals:
##     Min      1Q  Median      3Q     Max 
## -41.251 -13.695  -2.856  11.390 100.367 
## 
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)    
## (Intercept) -71.0332    23.5780  -3.013   0.0032 ** 
## aire$Temp     1.8402     0.2500   7.362 3.15e-11 ***
## aire$Wind    -3.0555     0.6633  -4.607 1.08e-05 ***
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 21.85 on 113 degrees of freedom
##   (37 observations deleted due to missingness)
## Multiple R-squared:  0.5687, Adjusted R-squared:  0.5611
## F-statistic:  74.5 on 2 and 113 DF,  p-value: < 2.2e-16
```

(a) El p-valor del test F es indicativo de que se podría ajustar un modelo no lineal.

(b) Los p-valores individuales corresponden a los tests de hipótesis $H_0 : \beta_i = 0$.

(c) No existen valores missing en el target.

(d) Ninguna de las anteriores es correcta.

7. Dada la siguiente salida de R de un modelo de regresión logística:

```
##
## Call:
## glm(formula = admit ~ gre + gpa + rank, family = "binomial",
##     data = mydata)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -1.6268  -0.8662  -0.6388   1.1490   2.0790
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -3.989979   1.139951  -3.500 0.000465 ***
## gre          0.002264   0.001094   2.070 0.038465 *
## gpa          0.804038   0.331819   2.423 0.015388 *
## rank2       -0.675443   0.316490  -2.134 0.032829 *
## rank3       -1.340204   0.345306  -3.881 0.000104 ***
## rank4       -1.551464   0.417832  -3.713 0.000205 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 499.98  on 399  degrees of freedom
## Residual deviance: 458.52  on 394  degrees of freedom
## AIC: 470.52
##
## Number of Fisher Scoring iterations: 4
```

¿Qué interpretación se puede hacer en términos de ODDS Ratio del parámetro *gpa*?

(a) Un aumento de la variable gpa en un punto, aumenta la odds ratio de la variable target en 0.804.

(b) Un aumento de la variable gpa en un punto, aumenta la odds ratio de la variable target en $e^{0.804}$.

(c) Ya aumente o disminuya la variable pga en un punto, habrá que ver cómo se comportan el resto de las variables para determinar la ODDS Ratio.

(d) Ninguna de las anteriores es correcta.

8. Durante la fase de modelado en un cliente del sector farmacéutico el responsable de negocio insiste en ajustar una regresión logística para predecir si su nuevo fármaco será comprado por alguna farmacéutica estadounidense en lugar de usar un árbol de decisión. ¿Cuál de los siguientes argumentos se le pueden plantear al cliente para realizar el árbol de decisión?

   (a) Los datos no son separables linealmente, y por ello se desaconseja la regresión logística.

   (b) Existe un gran número de variables categóricas con varios niveles que en la regresión logística no funcionan bien.

   (c) Las respuestas (a) y (b) son correctas.

   (d) Se realiza el modelo de regresión logística, a sabiendas que el resultado no va a ser el mejor posible.

9. Un cliente del sector editorial en plena transformación digital ha venido realizando hasta ahora sus segmentaciones en base a criterios que le han recomendado desde los departamentos de márketing y ventas. Nos solicita servicios para realizar una nueva segmentación de las librerías que tienen suscrito contrato de distribución. Se decide realizar un modelo K-Means, ¿cuál de las siguientes características del algoritmo es correcta?

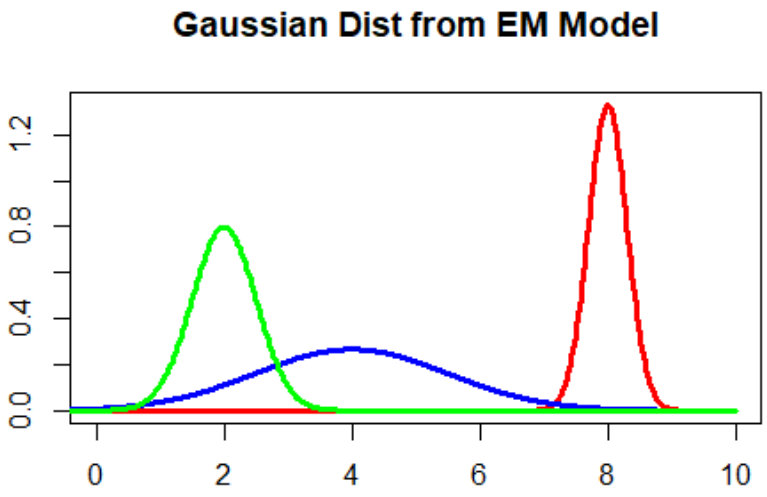
   (a) El K-Means garantiza resultados replicables 100% con cada lanzamiento.

(b) Con el K-Means se intentará conseguir la máxima homogeneidad intragrupos y la máxima heterogeneidad intergrupos.

(c) Con el K-Menas se intentará conseguir la máxima homogeneidad intergrupos y la máxima heterogeneidad intragrupos.

(d) El K-Means no es adecuado por el denominado "Efecto Bola de Nieve" que puediera haber entre las librerías.

10. Si se realizase una segmentación mediante el algoritmo EM usando mixturas de normales. A tenor del siguiente gráfico, ¿qué segmentos se podrían obtener?



(a) La distribución azul tiene valores solapados tanto en la distribución verde como en la roja, por lo que se debería dejar un único cluster.

(b) Las distribuciones verde y roja tienen las colas más pronunciadas, por ello deberían dejarse dos únicos clústeres, 1 hasta el valor x=5 y otro del valor x=5 en adelante.

(c) Hacer dos cortes, 1 en el valor x=3 aproximadamente, y otro en el valor x=7.2 y generar tres clústeres.

(d) Hacer tres cortes en la media de cada distribución: 2, 4 y 8 respectivamente y generar 4 clústeres.

11. En una red neuronal, ¿cuál es el problema de inicialización por descenso de gradiente?

(a) La inicialización por descenso de gradiente funciona exactamente igual que si se inicializase con valores de 0.5 en todos los parámetros.

(b) La saturación de la RAM del equipo.

(c) El descenso de gradiente puede encontrar un mínimo local afectando al entrenamiento de la red.

(d) La inicialización por descenso de gradiente no es un problema por sí sola, también afecta el número de variables que se esté utilizando para el entrenamiento de la red.

12. ¿Cuál de los siguientes elementos es necesario para aplicar un entrenamiento multicapa en una red neuronal?

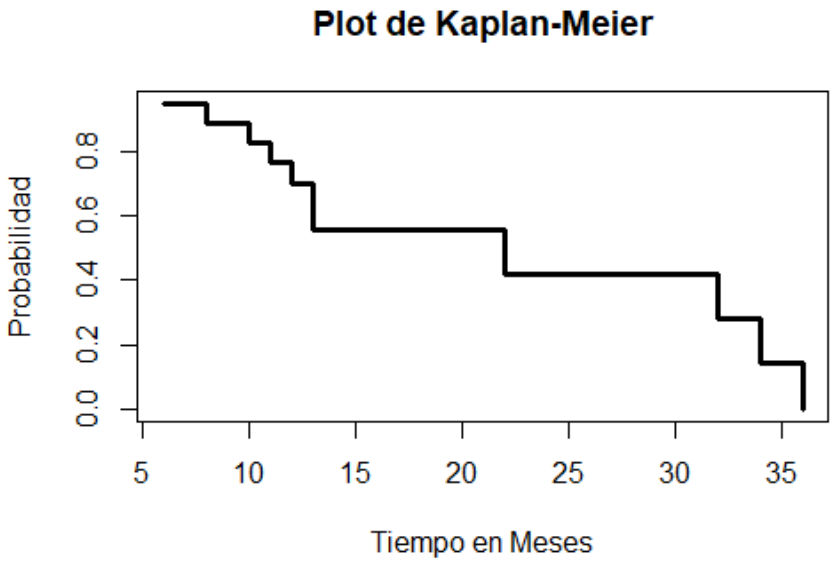
(a) Que la función de activación sea derivable.

(b) Que la función de activación sea derivable y con el menor número de variables posible.

(c) La función de activación no es necesaria para un entrenamiento multicapa.

(d) Ninguna de las anteriores es correcta.

13. Un cliente del sector banca solicita nuestros servicios para hacer una segmentación del cliente y un nuevo plan de fidelidad en base a los meses de uso de su nueva tarjeta de crédito + débito. El cliente nos asegura que en los últimos tres años todos sus clientes han hecho uso de su tarjeta de forma continua. Durante la fase de comprensión de datos se realiza un plot de Kaplan-Meier ¿qué conclusiones se le pueden transmitir al cliente?



(a) Durante el primer año de vida de la tarjeta se pierde a cerca del 40% de los clientes.

(b) Se pueden considerar a los clientes con más de 36 meses de uso de la tarjeta como "Clientes Platino".

(c) Se podrían extraer tres segmentos claros: menos de 12 meses, entre 12 y 30; y más de 30 meses.

(d) Las respuestas (a) y (c) son correctas.

14. Un cliente del sector Retail nos encarga un proyecto de Text Mining para conocer qué opiniones dejan los clientes acerca del proceso de compra on-line. Se decir realizar un modelo clásico de LDA y obtener un árbol de topics. ¿Cuál de los siguientes métodos es el más optimo para los LDA?

(a) Lanzar un único LDA con el número de categorías que solicite el cliente.

(b) Lanzar tópics muy genéricos para no abrumar al cliente y que se puedan explorar fácilmente en excel.

(c) Hacer varios lanzamientos de topics o muy genéricos o muy atomizados y encontrar el híbrido entre los dos.

(d) El Linear Discriminant Analysis no tiene sentido en los modelos de texto.

15. El mismo cliente del sector Retail, a mitad del proyecto, nos encarga también un Sentiment Analysis para ver cómo están poniendo sus clientes el mensaje. ¿Qué implicaciones tiene este cambio de alcance desde el punto de vista de Preparación de los datos?

    (a) La preparación del dato varía puesto que hay que tener en cuenta los modificadores de la oración.

    (b) Puede tener alguna implicación, pero debe ser gestionada por los líderes del proyecto.

    (c) No tiene ninguna implicación, tanto para el LDA como para el Sentiment la preparación es idéntica.

    (d) No tiene ninguna implicación, solo afectará a la fase de modelización porque hay que hacer dos modelos en lugar de uno.

16. Un cliente de distribución de moda solicita nuestros servicios para optimizar su red de centros logísticos a lo largo de la geografía española para que los camiones realicen el menor número de kilómetros posible. Dichos centros tienen una capacidad máxima de almacenamiento que permanece constante a lo largo del año, pero deben tramitar un volumen mínimo para poder permanecer operativas otro año más. Además hay que tener en cuenta el número de recursos que trabajan en cada centro por si hay que incrementar la plantilla. ¿Qué solución se le puede proponer al cliente?

    (a) Realizar un benchmark de los diferentes centros logísticos e intentar que todos tengan un comportamiento como el número 1 del benchmark.

    (b) Este tipo de planteamientos no son propios de Analytics y por tanto se debe rechazar la RFP.

    (c) Segmentar los centros logísticos y asignar un grupo de centros a cada empresa logística.

    (d) Realizar un modelo de optimización de redes basado en soluciones de investigación operativa.

17. Se desea entrenar un árbol de decisión y utilizar como función de split el índice de Gini. ¿Cuál de las siguientes características no se corresponde con dicho índice?

    (a) El índice de Gini oscila entre 0 y 0.5, siendo el 0 nivel máximo de desigualdad y 0.5 nivel máximo de inexistencia de desigualdad.

    (b) El índice de Gini es considerablemente mejor que utilizar una función basada en la entropía.

    (c) El índice de Gini se utiliza para modelados más laxos, mientras que la función entropía se utiliza para modelados más estrictos.

(d) Al igual que la función de entropía, el índice de Gini es una función parabólica que alcanza su máximo en el valor 0.5.

18. ¿Cuál de las siguientes funciones de linkage no se utilizan para modelos GLM?

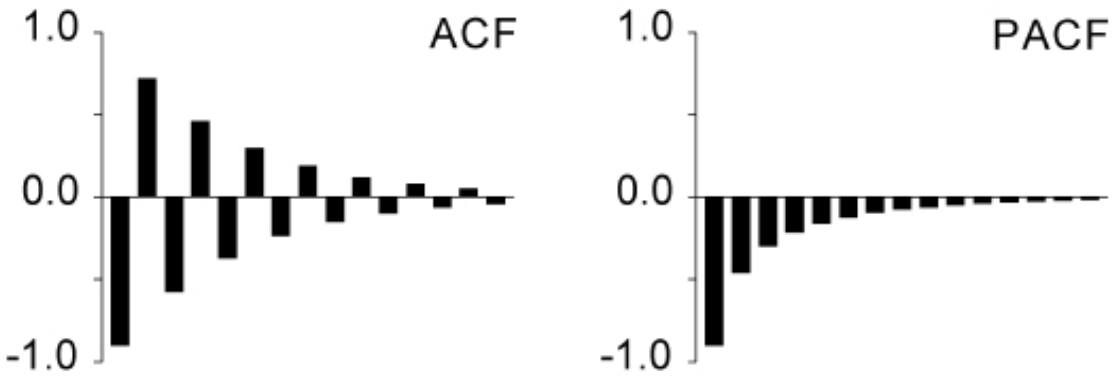
    (a) Logit

    (b) Probit

    (c) Clog-log

    (d) Todas son funciones de linkage.

19. Dadas las siguientes ACFs y PACFs, ¿cuál es el proceso de Box-Jenkins que mejor se ajustaría?



    (a) AR(2).

    (b) MA(1).

    (c) ARMA(1,1).

    (d) Ninguno de los anteriores.

20. En un cliente del sector automoción se desea ajustar la venta de coches mediante un modelo de forecasting. Durante la fase de comprensión de datos el cliente expone que a parte de la serie a modelar, existen ayudas estatales que afectan al nivel de serie. Estos cambios solo tienen efecto en el mes en el que son aprobados, y al mes siguiente la serie vuelve a su nivel normal. ¿Cuál de las siguientes técnicas solventarían el efecto de las ayudas estatales?

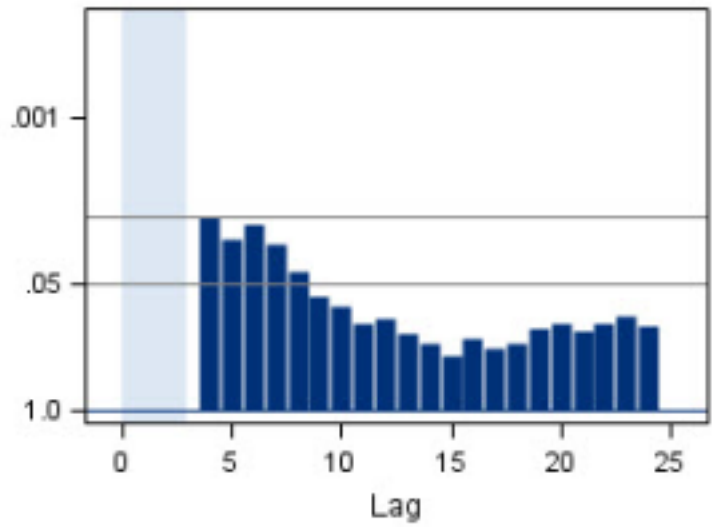
    (a) Reemplazando el valor del mes en el que se producen las ayudas por la media del resto de meses del año.

(b) Mediante una función de intervención con impulsos en los meses en los que se produzcan ayudas estatales.

(c) Suprimiendo los valores en los que se produzcan las ayudas y dejarlos a missing.

(d) Dejar que el modelo de forecasting amortigue dicho efecto con el paso de los meses.

21. Tras ajustar un modelo de series temporales, se ha realizado un text de Ljung-Box del que se ha obtenido la siguiente salida:



¿Qué interpretación merece el resultado de este test?

(a) Los residuos del modelo no son ruido blanco y hay falta de ajuste.

(b) Los drivers introducidos son todos significativos a un nivel de significancia de 0.05.

(c) El test de Ljung-Box no es un test apto para series temporales. Es un test que se utiliza para contrastar la normalidad de una variable.

(d) El proceso no es estacionario y por tanto no se debería haber ajustado un modelo de series temporales.

22. Tras realizar un ajuste de series temporales mediante un modelo ARIMA=(p,d,q)=(1,1,1) se quiere obtener la ecuación para la predicción, suponiendo el parámetro AR: ϕ_1 y el parámetro MA: θ_1 y una diferencia regular. ¿Cuál es la ecuación que representa el modelo ajustado?

(a) $(1-\phi_1 B)Y_t = (1-B)(1-\theta_1 B)a_t + \varepsilon_t$

(b) $(1-B)(1-\phi_1 B)Y_t = (1-\theta_1 B)a_t + \varepsilon_t$

(c) $Y_t - Y_{t-1} = \dfrac{(1-\theta_1 B)a_t}{(1-\phi_1 B)}$

(d) Las respuestas (b) y (c) son correctas

23. Tras haber realizado un modelo de clasificación, con la muestra de validación se obtiene la siguiente matriz de confusión. ¿Cuál de los siguientes valores no ha sido obtenido a partir de ella?

Real \ Predicho	0	1
0	150	23
1	27	100

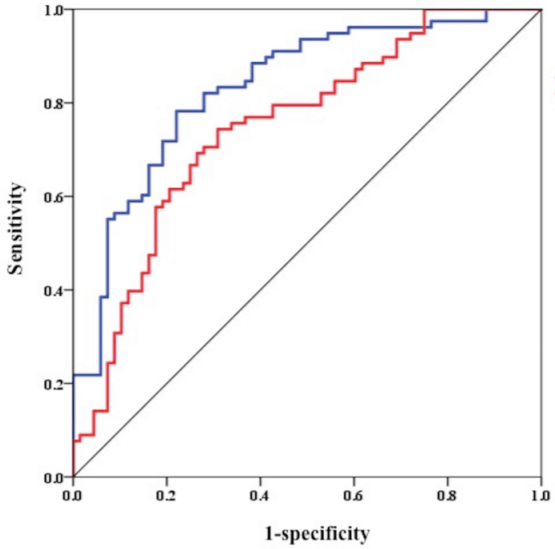
(a) 0.833

(b) 0.867

(c) 0.187

(d) Todas las anteriores son correctas.

24. Durante la fase de modelado de un problema de clasificación se han ajustado varios modelos que deben ser comparados para elegir el mejor de ellos. En base al siguiente gráfico, ¿qué se puede asumir de los modelos?



(a) El modelo rojo, puesto que en 1-Especifidad, en el tramo superior a 0.8, es mejor que el azul.

(b) El modelo azul, que tiene un área bajo la curva ROC superior al modelo rojo.

(c) Sin conocer los valores numéricos de área bajo la curva ROC no es posible hacer un juicio certero.

(d) Las dos están encima del baseline, las diferencias en términos de errores de predicción van a ser mínimas.

25. Durante la fase de evaluación de un modelo, dos consultores del equipo difieren de qué técnica es mejor para valorar un modelo sobre el conjunto de validación. Uno sostiene la realización de varios modelos mediante técnicas de Bootstrap y otro sostiene que es mejor realizar una validación mediante la técnica K-Fold. ¿Cuál de las dos técnicas es mejor para realizar tareas de validación?

(a) El bootstrap, puesto que así se conseguirán estimadores insesgados y por tanto de mejor calidad para el modelo.

(b) Ambas técnicas son similares, en estos casos la técnica de remuestreo es secundaria y no afecta a los resultados obtenidos.

(c) El K-Fold, puesto que el bootstrap está más pensado para la obtención de distribuciones y parámetros más que para la validación de modelos.

(d) Ninguna de las dos técnicas son útiles para valorar la calidad de un modelo.